



PRÉDICTION DE LA PERFORMANCE ÉTUDIANTE

Analyse, Modélisation et Évaluation

Augustin Owca
Brendan Robin
Antoine Geze
Noémie Petat

I. CONTEXTE & PROBLÉMATIQUE

CONTEXTE ET ENJEUX

L'éducation moderne cherche à identifier les leviers de la réussite scolaire de manière proactive.

Constat : La performance académique est influencée par de nombreux facteurs (environnement familial, qualité de l'enseignement, motivation, heures d'étude, sommeil, etc.).

Enjeu : Les établissements scolaires ont besoin d'anticiper les risques d'échec afin d'optimiser leurs actions d'accompagnement.

Objectif : Proposer un système d'analyse prédictive pour identifier les facteurs déterminants de la réussite.



PROBLÉMATIQUE ET OBJECTIFS

- Comment anticiper avec précision la performance académique d'un élève à partir de ses données sociodémographiques et comportementales ?
- Quels sont les leviers sur lesquels les équipes pédagogiques peuvent agir pour améliorer son accompagnement ?

Objectif principal :

- Développer un modèle de Machine Learning capable d'estimer la note finale d'un élève à partir de variables explicatives et de mettre en évidence les facteurs les plus déterminants.
- Déployer une plateforme interactive et intuitive pour pouvoir simplement exploiter le modèle en temps réel.

Objectif technique :

Atteindre une performance de $R^2 > 0.75$.

II. PRÉSENTATION DU DATASET

PRÉSENTATION DU **DATASET**

6 607

ÉTUDIANTS ANALYSÉS

Volume faible ce qui crée un
risque de surapprentissage

20

CARACTÉRISTIQUES

Ensemble de variables permettant de
dresser le profil des élèves (données
sociodémographiques,
comportementales et pédagogiques)

TYPOLOGIE DES DONNÉES



Académique

Variables liées
directement au cursus :
Heures d'étude, scores
précédents, sessions de
tutorat, assiduité en
classe.



Environnement

Le cadre de vie de l'élève :
Implication parentale,
accès à internet, type
d'école (public/privé),
distance du domicile.




Comportement



Habitudes personnelles :
Activités extrascolaires,
heures de sommeil,
influence des pairs,
activité physique.

RÉPARTITION DES DONNÉES

- **Nettoyage des données :** traitement des valeurs manquantes, gestion des outliers et suppression des doublons.
- **Analyse exploratoire :** étude de la variable cible Exam_Score en fonction des 20 caractéristiques du dataset.





IMPACT ASSIDUITÉ



- **Relation positive** : ↗ présence en cours → ↗ score à l'examen.
- Dispersion des résultats : **la présence seule** n'explique pas entièrement la performance.
- Effet de la motivation : à présence égale, ↗ motivation → score légèrement ↗.


RÉPARTITION HEURES D'ÉTUDES



- **Relation positive** : ↗ heures d'étude → ↗ score à l'examen.
- Dispersion des résultats : **le temps d'étude seul** n'explique pas entièrement la performance.
- Effet de la motivation : à effort égal, ↗ motivation → score ↗ légèrement

IMPACT


NIVEAU D'ÉDUCATION DES PARENTS



- Différences faibles mais progressives entre les niveaux d'éducation parentale.
- **Postgraduate** : médiane légèrement plus élevée.
- **High School et College** : résultats très proches.
- **Impact global limité de l'éducation parentale sur la performance.**

IMPACT

ACCÈS AUX RESSOURCES




Les différences sont plus visibles ici :

- Accès High → médiane légèrement plus élevée.
- Accès Low → médiane plus basse.

L'accès aux ressources semble avoir un impact plus marqué que le niveau d'éducation des parents.

IMPACT


IMPLICATION DES PARENTS



- **Progression légère des scores** : Low < Medium < High.
- **Implication parentale plus élevée** → score légèrement plus élevé.
- Écart modéré entre les groupes : **impact positif mais limité.**

CORRÉLATION

PRINCIPALES



Facteurs les plus corrélés avec le score :

- **Attendance**
- **Hours_Studied**

Facteurs secondaires :

- **Previous_Scores**
- **Access_to_Resources**
- **Parental_Involvement**
- **Tutoring_Sessions**

III. MÉTHODOLOGIE & MODÉLISATION

PIPELINE DE PRÉTRAITEMENT

1

Imputation

Valeurs manquantes :

- Numérique → **médiane**
- Catégoriel → **mode**

3

Standardisation

- **StandardScaler**
- **Mise à l'échelle** des variables
- Améliore **la stabilité** des modèles de régression

2

Encodage

- Variables catégorielle → **Encodage ordinal**
- Permet aux modèles ML d'exploiter les catégories

Low	Medium	High
0	1	2

4

Split des données

- **Train : 80 %**
- **Test : 20 %**

MODÈLES UTILISÉS

Algorithme Testé	RMSE (Erreur Moyenne)	R ² (Variance Expliquée)
Régression Linéaire (Baseline)	1.80	0.77
Random Forest Regressor	2.16	0.67
Stacking (Ridge + Gradient Boosting)	1.80	0.77


Phénomène de Surapprentissage (Overfitting) sur le Random Forest : le modèle capture le "bruit" au lieu de la tendance générale.



IV. RÉSULTATS & LIMITES

RÉSULTATS

- Très bon alignement des points entre 55 et 75.
- Les prédictions suivent bien la diagonale.
- $R^2 \approx 0.77 \rightarrow$ le modèle explique 77% de la variance. Le modèle est globalement performant.



Pour les scores très élevés (80–100) le modèle sous-estime fortement :

- Seulement 0.65% du dataset (43 élèves) ont un score > 80
- Le mécanisme mathématique du modèle pénalise et écrase les valeurs extrêmes

LIMITES




**Corrélation
vs Causalité**



Biais des données



Taille Dataset



V. DÉMO



MERCI